

ML Start 2026: домашнее задание #3

Тема 24: глубина vs ширина MLP

Сорочан Дмитрий

1 Постановка задачи

Цель работы — исследовать, как глубина и ширина многослойного перцептрона влияют на качество. Используются оба корпуса из темы 24 — MNIST и Fashion-MNIST — и отдельный блок с синтетическими функциями. Для классификации вход имеет 784 пикселя, выход — 10 классов.

Базовая архитектура намеренно простая:

$$x \rightarrow \text{Flatten} \rightarrow (\text{Linear} \rightarrow \text{ReLU})^d \rightarrow \text{Linear}(10).$$

Фиксированы Adam, learning rate и weight decay. Это позволяет менять именно d и w , а не одновременно архитектуру, scheduler, BatchNorm и residual connections.

Для одинаковой ширины число параметров зависит от глубины:

$$P(d, w) = (784 + 1) \cdot w + (d - 1) \cdot (w + 1) \cdot w + (w + 1) \cdot 10.$$

Поэтому кроме обычного sweep проведен parameter-matched эксперимент, где shallow и deep сети сравниваются при близком числе параметров.

1.1 Теоретическая мотивация

Теорема об универсальной аппроксимации говорит, что достаточно широкая сеть с одним скрытым слоем и подходящей нелинейностью может приближать непрерывные функции на компакте. Но теорема не говорит, какая ширина нужна, как найти веса и насколько хорошо модель будет обобщать. Глубина может быть параметрически выгоднее, но очень глубокую plain MLP тяжелее оптимизировать. Работа проверяет именно этот компромисс.

2 Данные, EDA и признаки

MNIST и Fashion-MNIST имеют одинаковый формат: 60 000 train, 10 000 official test, изображения 28×28 , 10 классов. Пропусков и категориальных признаков нет. Fashion-MNIST визуально сложнее из-за похожих классов верхней одежды.




Рис. 1: баланс классов (слева) и корреляции engineered features (справа).




Рис. 2: MNIST: engineered features по классам (слева) и Fashion-MNIST: engineered features по классам (справа).

Для классических моделей к 784 пикселям добавлены пять image-level признаков: средняя яркость, стандартное отклонение пикселей, доля активных пикселей и координаты центра массы. Коррелированные признаки не удаляются автоматически: для деревьев корреляция не нарушает корректность обучения, но importance может распределяться между похожими признаками.

В EDA дополнительно строятся распределения каждого engineered feature по 10 классам отдельно для MNIST и Fashion-MNIST. Это позволяет проверить, несут ли глобальная заполненность, контраст и центр массы class-conditional сигнал до обучения классических моделей.

Основная метрика — **balanced accuracy**; дополнительно считаются macro-F1, macro-precision и macro-recall. Хотя оба корпуса почти сбалансированы, единая метрика делает все сравнения согласованными.

3 Глубина и ширина MLP

Основная прямоугольная сетка:

$$d \in \{1, 2, 3, 5, 10, 20, 50, 100\}, \quad w \in \{8, 16, 32, 64, 128, 256, 512, 1024, 2048\}.$$

На каждой точке фиксированы train subset, validation, число эпох, optimizer и regularization. Early stopping в sweep не используется, чтобы разные архитектуры получили одинаковый training budget.




Рис. 3: MNIST: width × depth (слева) и Fashion-MNIST: width × depth (справа).

Широкие сети входят в тот же основной sweep, поэтому отдельного второго прохода нет. Для сочетаний свыше 20 млн параметров обучение пропускается до создания модели: например,

$d = 100, w = 2048$ потребовал бы сотни миллионов параметров и многогигабайтные состояния Adam. Такие точки проверяли бы прежде всего доступную память, а не архитектурный эффект.

3.1 Learning curves, регуляризация и CV

Weight decay 10^{-4} используется одинаково для всех MLP. На learning curves train и validation loss строятся на одном графике; отдельно сравнивается balanced accuracy. Это позволяет отличить переобучение от ситуации, когда deep-сеть просто плохо оптимизируется.




Рис. 4: MNIST: train/validation loss (слева) и Fashion-MNIST: train/validation loss (справа).

Большой sweep выполняется на одном фиксированном stratified hold-out split. После выбора архитектура дополнительно проверяется 5-fold StratifiedKFold на train subset. Это не используется как новый поиск hyperparameters, а служит проверкой устойчивости выбранной конфигурации.

Official test не участвует ни в sweep, ни в CV. После выбора сеть переобучается на всей official train-части и test оценивается один раз.

4 Классические модели

Проверяются GaussianNB, Logistic Regression и Random Forest. Внешний validation отделяется заранее; GridSearchCV работает только на train через 5-fold StratifiedKFold. StandardScaler для Logistic Regression находится внутри Pipeline.

Для Random Forest не задается искусственный лимит глубины. GridSearchCV выполняется последовательно (`SEARCH_N_JOBS=1`), а параллелизм остается только внутри самого леса. Это избегает nested joblib-parallelism и лишних пиков памяти.




Рис. 5: MNIST: Random Forest feature importance.

Feature importance имеет реальные имена: `pixel_row_col` и пять engineered features.

5 Confusion matrix и анализ ошибок

Для лучших моделей строятся normalized confusion matrix и таблица наиболее частых направленных ошибок `true -> predicted`. На Fashion-MNIST особенно важны пары Shirt/T-shirt/top/Pullover/Coat; это согласуется с EDA. На MNIST ошибки менее выражены и распределены между визуально похожими написаниями цифр.




Рис. 6: MNIST: лучшая классика (слева) и Fashion-MNIST: MLP (справа).

6 Синтетические функции

Выбраны четыре структуры: почти линейная функция, полином, периодическая функция и Heaviside. Теперь одна и та же сетка $d \times w$ прогоняется **по всем четырем функциям**, а не только по `periodic`. Это важно: оптимальная архитектура может зависеть от гладкости и локальной структуры целевой зависимости.




Рис. 7: Выбранные синтетические функции.




Рис. 8: MSE heatmap width $\times$ depth для всех четырех функций.

В старой версии конфигурация $d = 20, w = 32$ иногда превращалась почти в горизонтальную прямую. Проверка показала, что это был реальный optimization collapse, а не баг визуализации:

стандартная инициализация вместе с 20 слоями Tanh почти уничтожала вариативность сигнала. Для всех конфигураций одинаково введена Xavier initialization с gain для Tanh и $LR = 3 \cdot 10^{-3}$. В контрольном запуске periodic для $d = 20, w = 32$ получила MSE около $1.6 \cdot 10^{-3}$ и перестала быть константой. Большой synthetic sweep запускается на CPU: для 1D-данных GPU не нужен, а это исключает накопление MPS allocator cache при последовательном создании десятков моделей.

Heaviside остается принципиально особым примером: конечная MLP с непрерывными активациями непрерывна, поэтому точный скачок в sup-норме она не воспроизводит, хотя MSE может быть малым за счет узкой переходной области.

7 Blending и корреляции моделей

Проверяются equal-weight и metric-weighted soft voting. Metric-based численные веса пропорциональны CV balanced accuracy на train. Однако MLP-архитектура до этого выбиралась по hold-out validation, поэтому весь blend-score трактуется как exploratory, а не как независимая test-оценка ансамбля. Для строгой финальной оценки потребовался бы отдельный untouched split для blending.

Перед blending строятся две таблицы: корреляция развернутых probability predictions и корреляция бинарных индикаторов ошибок. Коррелировать номера классов нельзя — это категориальные метки, а не числовая шкала.




Рис. 9: MNIST: корреляции predictions/errors (слева) и Fashion-MNIST: корреляции predictions/errors (справа).




Рис. 10: Fashion-MNIST: одиночные модели и варианты blending.

В сохраненном прогоне probabilities LR/RF/MLP высоки, примерно 0.94–0.95, а корреляции индикаторов ошибок умеренные. Поэтому большой прирост от простого усреднения не ожидается. На MNIST лучшая одиночная MLP осталась сильнее blend; на Fashion-MNIST equal blend улучшил balanced accuracy примерно с 0.8782 до 0.8804, metric-weighted — до 0.8805. Отсутствие большого прироста здесь является содержательным отрицательным результатом, а не ошибкой кода.

8 Корректность, leakage и воспроизводимость

- единый SEED=143 для split, CV, NumPy, Python и PyTorch;
- все сравниваемые корпуса используют одинаковый hold-out validation protocol;
- official test не участвует в выборе архитектуры, hyperparameters или blend weights;
- StandardScaler обучается только внутри CV Pipeline;
- GridSearchCV видит только train, внешний validation остается контролем;
- metric-based blend вычисляет численные веса из train-CV scores; поскольку MLP-кандидат выбран по validation, сами blend-метрики явно помечены как exploratory;
- перед blending проверяется идентичность порядка `y_true` во всех NPZ;
- synthetic initialization и learning rate одинаковы для всех depth/width;
- результаты сохраняются в `/mlStart/hws/output` независимо от cwd kernel.

9 Чек-лист задания и итог

Выполнены EDA, feature engineering, три классических алгоритма, GridSearchCV и 5-fold CV, MLP с learning curves и регуляризацией, сравнение качества/времени, confusion matrix и error analysis. Для темы 24 есть MNIST, Fashion-MNIST, synthetic functions, единый sweep с ширинами 8–2048, heatmap, parameter-matched shallow/deep и MSE heatmap по всем синтетическим функциям. Бонусы закрыты feature importance, blending, correlation analysis и GitHub-ready оформлением.

Главный вывод: глубину и ширину нельзя оценивать отдельно от training budget и числа параметров. Ширина обычно дает насыщение, тогда как чрезмерная глубина plain MLP может ухудшать оптимизацию. Но и этот эффект надо отделять от технических артефактов вроде неудачной инициализации — именно поэтому synthetic block использует одинаковую Xavier initialization и отдельные learning curves.

Численные результаты после полного запуска

MNIST: final MLP test balanced accuracy = 0.9791, macro-F1 = 0.9790; 5-fold CV = 0.9555 ± 0.0051 ; лучшая validation model = MLP (0.9672); лучший blend = MLP (0.9672).

Fashion-MNIST: final MLP test balanced accuracy = 0.8893, macro-F1 = 0.8888; 5-fold CV = 0.8492 ± 0.0087 ; лучшая validation model = MLP (0.8746); лучший blend = Blend: all equal (0.8816).

near linear: best depth=5, width=16, MSE=0.000064.

polynomial: best depth=5, width=32, MSE=0.000174.

periodic: best depth=10, width=8, MSE=0.000478.

heaviside: best depth=30, width=8, MSE=0.000092.