

ML Start 2026: домашнее задание #3

Тема 24: глубина vs ширина MLP

Сорочан Дмитрий

1 Что исследуется

Задача темы 24 — понять, как число скрытых слоев и ширина MLP влияют на качество аппроксимации. Исследование проведено на трех типах данных из условия: MNIST, Fashion-MNIST и синтетических функциях. Для корпусов задача — многоклассовая классификация изображений 28×28 , для синтетики — одномерная регрессия.

Исследуемая сеть намеренно простая:

$$x \rightarrow \text{Flatten} \rightarrow (\text{Linear} \rightarrow \text{ReLU})^d \rightarrow \text{Linear}(10).$$

Фиксированы Adam, learning rate и weight decay. Это важно: если одновременно менять BatchNorm, residual connections и scheduler, станет непонятно, что именно дало прирост — глубина или дополнительная техника оптимизации.

Для d скрытых слоев ширины w число параметров равно

$$P(d, w) = (784 + 1) \cdot w + (d - 1) \cdot (w + 1) \cdot w + (w + 1) \cdot 10.$$

Поэтому кроме обычной сетки $d \times w$ проведен отдельный parameter-matched эксперимент: shallow и deep сети сравниваются при близком числе параметров.

1.1 Почему shallow-сеть вообще имеет шанс

Теорема об универсальной аппроксимации гарантирует существование достаточно широкой однослойной сети, приближающей непрерывную функцию на компакте. Но это утверждение не дает эффективной ширины, алгоритма поиска весов или гарантии обобщения. Глубина может быть параметрически выгоднее для композиционных зависимостей, но plain deep MLP при этом может хуже оптимизироваться. Именно этот конфликт и проверяется экспериментально.

2 EDA, preprocessing и feature engineering

Оба корпуса содержат 60000 train и 10000 test изображений, 10 классов и одинаковый размер входа. Исходные пиксели — 'uint8', пропусков и категориальных признаков нет. Редкие формы не удаляются как выбросы: в изображениях нет основания считать необычную цифру ошибкой наблюдения.



Рис. 1: Случайные примеры Fashion-MNIST: несколько классов верхней одежды визуально близки.




Рис. 2: Корреляции engineered признаков.

В EDA есть требуемые распределения, boxplot и correlation matrix для engineered признаков. Для feature engineering построены пять простых глобальных признаков: средняя яркость, стандартное отклонение пикселей, доля активных пикселей и две координаты центра массы. Они добавляются только в классические модели (с удалением первых двух как коррелированных с третьим). MLP получает исходные пиксели, чтобы исследование архитектуры не смешивалось с ручным представлением данных.

Основная метрика — **balanced accuracy**. На этих корпусах дисбаланс слабый, но единая метрика делает сравнение согласованным. Также считаются макро-F1, макро-precision и макро-recall.

3 Эксперимент с архитектурой MLP

Основная сетка: $d \in \{1, 2, 3, 5, 10, 20, 50, 100\}$ и $w \in \{8, 16, 32, 64, 128, 256\}$. Все комбинации получают одинаковое число эпох и одинаковый optimizer budget. Early stopping в sweep не используется именно ради честности сравнения.




Рис. 3: MNIST: balanced accuracy для сетки width × depth.




Рис. 4: Fashion-MNIST: balanced accuracy для сетки width $\times$ depth.

Heatmap дополняется графиками по глубине/ширине и parameter-matched ablation. Последний особенно важен: он отделяет пользу глубины от банального увеличения числа обучаемых параметров.




Рис. 5: MNIST: shallow vs deep при сопоставимом числе параметров.

3.1 Learning curves и регуляризация

Требование по регуляризации закрыто фиксированным weight decay 10^{-4} . Он одинаков для всех архитектур и поэтому не превращается в дополнительную ось подбора.

На learning curves train и validation loss показаны на одном графике. Отдельно строится аналогичный график balanced accuracy.




Рис. 6: MNIST: train и validation loss для нескольких характерных архитектур.




Рис. 7: Fashion-MNIST: train и validation loss.

3.2 Cross-validation и test protocol

Большой sweep выполняется на одном фиксированном stratified split, иначе полный 48-точечный grid пришлось бы повторять пять раз. После выбора кандидата лучшая архитектура дополнительно проходит 5-fold StratifiedKFold на той же train-подвыборке. Это проверяет устойчивость результата к конкретному разбиению.

Official test не участвует ни в sweep, ни в CV. После выбора архитектура переобучается на всей official train-части и test оценивается один раз. Такой порядок исключает превращение test в скрытый validation.

4 Классические модели

Для общей части задания используются три модели: GaussianNB, Logistic Regression и Random Forest. Внешний validation отделяется заранее. Подбор гиперпараметров выполняется только на train через 5-fold StratifiedKFold и GridSearchCV. Scaling Logistic Regression находится внутри Pipeline, поэтому статистики scaler не видят validation-fold заранее.

Random Forest не ограничивается по глубине (`max_depth=None`). Для Logistic Regression установлен высокий общий `MAX_ITER`, чтобы линейный baseline успевал сойтись. Итог сравнивается по тем же balanced accuracy, macro-F1, precision/recall и времени обучения.




Рис. 8: MNIST: сравнение классических моделей по нескольким метрикам.




Рис. 9: Fashion-MNIST: сравнение классических моделей.

4.1 Feature importance

Interpretability закрывается встроенной feature importance Random Forest. В 'output' сохраняются top-25 признаков: это либо конкретные пиксели, либо engineered brightness/std/density/center features. Такой график позволяет проверить, использует ли boosting ручные признаки или почти полностью восстанавливает форму по пикселям.




Рис. 10: MNIST: top-25 признаков Random Forest.




Рис. 11: Fashion-MNIST: top-25 признаков Random Forest.

5 Confusion matrix и error analysis

Для Fashion-MNIST заранее ожидаемая сложная группа — ‘T-shirt/top’, ‘Shirt’, ‘Pullover’, ‘Coat’: EDA показывает близкие силуэты. Если эти пары оказываются наверху фактической

таблицы ошибок, confusion matrix дает содержательное объяснение снижения качества. Для MNIST пары не фиксируются заранее: вывод строится по фактическим top-confusions после запуска.




Рис. 12: MNIST: normalized confusion matrix лучшей классической модели.




Рис. 13: Fashion-MNIST: normalized confusion matrix финальной MLP.

6 Синтетические функции

Выбраны четыре функции с разной структурой: почти линейная, полиномиальная, периодическая и Heaviside. Первая служит sanity check, полином дает гладкую нелинейность, периодическая функция используется для width $\times$ depth heatmap, а Heaviside показывает ограничение

непрерывной MLP на разрыве.




Рис. 14: Четыре синтетические функции.




Рис. 15: Периодическая функция: MSE.




Рис. 16: Аппроксимация Heaviside: непрерывная сеть сглаживает скачок.

Забавный факт: стандартная MLP непрерывна. Поэтому последовательность таких сетей не может равномерно сойтись к разрывной Heaviside на всем отрезке; при этом MSE может быть малым, если зона перехода становится узкой.

7 Blending

Проверяются два fixed-weight soft-vote ансамбли: две классические модели и те же модели плюс MLP. Веса не оптимизируются на validation, чтобы бонусный эксперимент не превратился в еще один скрытый hyperparameter search. Если blend улучшает balanced accuracy, значит ошибки моделей достаточно различаются; если нет, это указывает на сильную корреляцию ошибок.




Рис. 17: MNIST: отдельные модели и blends.

8 Корректность и воспроизводимость

- единый 'SEED=143' для NumPy, Python, PyTorch и всех split;
- StratifiedKFold с 5 фолдами для классики и отдельной проверки выбранной MLP;
- test не участвует в выборе архитектуры или hyperparameters;
- scaling Logistic Regression находится внутри Pipeline;

- все модели сравниваются по одной системе метрик;
- RF и LightGBM не урезаны искусственным `max_depth`;
- результаты сохраняются в 'hws/output', независимо от cwd Jupyter kernel.

9 Чек-лист задания

- EDA и preprocessing — выполнены;
- 2-3+ engineered features — выполнено, построено пять;
- минимум три классических алгоритма — выполнено, четыре;
- hyperparameter search — GridSearchCV;
- минимум 5-fold CV — выполнено;
- MLP architecture rationale — выполнено;
- train/val loss и метрика по эпохам — выполнено;
- regularization — weight decay;
- сравнение качества и времени — выполнено;
- тема 24: MNIST, Fashion-MNIST, synthetic, heatmap, parameter-matched shallow/deep — выполнено;
- bonus feature importance — выполнено;
- bonus blending — выполнено;
- bonus error analysis — выполнено;
- GitHub-ready README + requirements — выполнено.

Бонус interpretability выполнен через feature importance; SHAP отдельно не нужен, поскольку в условии указан вариант “SHAP / feature importance”.

Численные результаты после полного запуска

MNIST: final MLP test balanced accuracy = 0.9816, macro-F1 = 0.9816. 5-fold CV selected MLP: 0.9528 ± 0.0035 . Лучшая validation model: MLP (0.9671). Лучший fixed-weight blend: MLP (0.9671).

Fashion-MNIST: final MLP test balanced accuracy = 0.8887, macro-F1 = 0.8884. 5-fold CV selected MLP: 0.8550 ± 0.0039 . Лучшая validation model: MLP (0.8782). Лучший fixed-weight blend: Blend: classical + MLP (0.8804).

Dataset	Model	BalAcc	F1	Precision	Recall	Time, s
MNIST	Random Forest	0.9570	0.9571	0.9572	0.9570	176.7
MNIST	Logistic Regression	0.9077	0.9075	0.9075	0.9077	3.4
MNIST	GaussianNB	0.5667	0.5288	0.6603	0.5667	0.6
Fashion-MNIST	Random Forest	0.8735	0.8722	0.8725	0.8735	509.9
Fashion-MNIST	Logistic Regression	0.8467	0.8465	0.8465	0.8467	13.4
Fashion-MNIST	GaussianNB	0.6180	0.5892	0.6698	0.6180	0.6
MNIST	MLP	0.9671	0.9672	0.9674	0.9671	12.0
Fashion-MNIST	MLP	0.8782	0.8789	0.8818	0.8782	11.6

Периодическая синтетическая функция: лучшая точка heatmap depth=5, width=64, MSE=0.000587.

10 Итог

Поднимаемый вопрос: когда дополнительная глубина дает пользу при контроле ширины, training budget и числа параметров. Heatmap показывает глобальную картину, parameter-matched эксперимент контролирует complexity, learning curves объясняют оптимизацию, CV — устойчивость, а confusion matrix — структуру оставшейся ошибки. Синтетика дополняет классификацию примером, где истинная функция известна, включая разрывную Heaviside, на которой особенно хорошо видны ограничения непрерывной MLP.

В общем случае, как удалось убедиться, нужен баланс: слишком широкая сеть избыточна, слишком глубокая покажет себя плохо из-за затухания градиентов.