

Домашнее задание #3

Пет-проект: классическое ML + нейронные сети

Курс ML Start 2026

Дедлайн: воскресенье, 23.08.2026, 23:59

Цель задания

Выполнить самостоятельный ML-проект от постановки задачи до выводов. Вы выбираете одну тему из списка ниже и проводите полноценное исследование: собираете/загружаете данные, строите модели (классические + MLP), сравниваете результаты и оформляете отчёт.

Это задание объединяет все знания курса: EDA, feature engineering, классические алгоритмы, нейронные сети, регуляризация, оптимизация.

Формат сдачи

1. Jupyter Notebook (.ipynb) — весь код с результатами выполнения
2. PDF-отчёт (3–8 страниц) — описание, визуализации, таблицы, выводы
3. (бонус) Ссылка на GitHub-репозиторий с README

Выбор темы

Выберите одну тему из списка. Если хотите свою тему — согласуйте с преподавателем.

А. Финансовая аналитика

1. Детектор финансового мошенничества
Система обнаружения подозрительных транзакций. Сравните Isolation Forest, One-Class SVM, ансамбли и MLP. Изучите временные паттерны, проанализируйте ложные срабатывания.
Датасет: Credit Card Fraud Detection (Kaggle), IEEE-CIS Fraud Detection.
2. Скоринговая модель для микрофинансирования
Кредитный скоринг для людей без кредитной истории. Исследуйте fairness алгоритмов (дискриминация по полу/возрасту), interpretability через SHAP.
Датасет: Home Credit Default Risk (Kaggle), German Credit Data.
3. Предсказание оттока клиентов (Churn Prediction)
Спрогнозируйте, уйдёт ли клиент из сервиса. Проведите анализ бизнес-метрик:

стоимость удержания vs потеря клиента, ROI модели. Сравните логистическую регрессию, градиентный бустинг и MLP.

Датасет: Telco Customer Churn (Kaggle), Bank Customer Churn (Kaggle).

4. Предсказание дефолта по кредитным картам

Бинарная классификация: заплатит ли клиент в следующем месяце. Исследуйте дисбаланс классов (SMOTE, class weights), постройте калибровочные кривые для оценки вероятностей.

Датасет: Default of Credit Card Clients (UCI), Amex Default Prediction (Kaggle).

5. Прогнозирование цен акций

Предскажите направление движения цены (вверх/вниз) на основе технических индикаторов (RSI, MACD, Bollinger Bands). Сравните классические модели и MLP на скользящих окнах. Оцените, побьёте ли random baseline.

Датасет: Yahoo Finance API, Alpha Vantage, Kaggle Stock Market datasets.

6. Сегментация клиентов банка

Кластеризация клиентов (K-Means, DBSCAN, GMM) + классификация новых клиентов по сегментам. Визуализируйте сегменты через t-SNE/UMAP, составьте бизнес-профили кластеров.

Датасет: Credit Card Dataset for Clustering (Kaggle), Bank Marketing (UCI).

В. Экология и климат

7. Предсказание лесных пожаров

Вероятность и масштаб пожаров на основе метеоданных. Исследуйте сезонные паттерны, создайте карты риска. Сравните Random Forest, XGBoost и MLP.

Датасет: Forest Fires Data Set (UCI), MODIS Burned Area Product.

8. Анализ качества воздуха в мегаполисах

Предсказание уровня PM2.5. Изучите корреляцию с транспортным трафиком, погодой, выходными днями.

Датасет: Beijing PM2.5 Data Set, OpenAQ Global Air Quality Data.

9. Классификация типов почв по спутниковым данным

Мультиклассовая классификация на основе спектральных характеристик. Примените PCA для снижения размерности, сравните SVM (разные ядра) и MLP.

Датасет: Covertypes Dataset (UCI), EuroSAT.

10. Прогнозирование энергопотребления зданий

Предскажите почасовое потребление электроэнергии по погоде, типу здания и времени суток. Feature engineering: циклические признаки (час, день недели), лаговые значения. Сравните бустинг и MLP.

Датасет: ASHRAE Energy Prediction (Kaggle), UCI Appliances Energy Prediction.

11. Предсказание урожайности сельскохозяйственных культур

Регрессия урожайности по климату, типу почвы, осадкам и удобрениям. Исследуйте нелинейные зависимости, постройте карты важности признаков по регионам.

Датасет: Crop Yield Prediction (Kaggle), FAO FAOSTAT.

12. Классификация видов животных по следам активности

Определите вид животного по данным с камер-ловушек (метаданные: время, температура, локация, длительность). Мультиклассовая задача с сильным дисбалансом. Примените ансамбли и MLP.

Датасет: Snapshot Serengeti (Lila.science), iWildCam (Kaggle).

C. NLP и текстовые данные

13. Детекция спама в SMS

Классификация сообщений на спам/не спам. Сравните TF-IDF + Naive Bayes/SVM/LogReg и TF-IDF + MLP. Исследуйте, какие слова наиболее информативны.

Датасет: SMS Spam Collection (UCI), Enron Spam Dataset.

14. Анализ тональности отзывов на русском языке

Sentiment analysis отзывов (позитивный / негативный / нейтральный). TF-IDF + классика vs MLP. Исследуйте влияние предобработки: стемминг, лемматизация, стоп-слова.

Датасет: RuSentiment, отзывы с Кинопоиска/Ozon/Wildberries.

15. Классификация новостных статей по темам

Мультиклассовая классификация (политика, спорт, технологии, экономика и т.д.). Сравните Bag-of-Words vs TF-IDF, N-граммы разных порядков. Постройте confusion matrix и проанализируйте, какие темы путаются.

Датасет: AG News (Kaggle), 20 Newsgroups (sklearn), Lenta.ru dataset.

16. Детекция токсичных комментариев

Мульти-лейбл классификация: оскорбление, угроза, ненависть и т.д. Исследуйте порог классификации для каждого лейбла, оцените Precision-Recall tradeoff.

Датасет: Jigsaw Toxic Comment Classification (Kaggle), Russian Toxic Comments.

17. Автор текста: стилометрия

Определите автора текста по стилистическим признакам: длина предложений, частотность частей речи, лексическое разнообразие, знаки препинания. Сравните ручной feature engineering + классику и TF-IDF + MLP.

Датасет: Project Gutenberg (книги разных авторов), корпус русской прозы.

D. Исследование алгоритмов

18. Бенчмарк 15+ алгоритмов на 10+ датасетах

Создайте масштабное сравнение: LogReg, SVM, KNN, Decision Tree, Random Forest, ExtraTrees, AdaBoost, GradientBoosting, XGBoost, LightGBM, CatBoost, Naive Bayes, MLP (разные архитектуры). Постройте карту применимости: какой алгоритм лучше для каких данных.

Датасет: OpenML-CC18 benchmark suite.

19. Bias-Variance Decomposition на практике

Реализуйте разложение ошибки на bias и variance для 5+ алгоритмов. Визуализируйте tradeoff при изменении сложности модели (глубина дерева, число нейронов, степень полинома).

Датасет: синтетические данные + 2-3 реальных датасета.

20. AutoML-бенчмарк: ручной подбор vs автоматический
Сравните качество и время: ваш ручной подбор (GridSearch/Optuna) vs Auto-sklеarn / FLAML / H2O AutoML. На каких задачах AutoML побеждает, а где проигрывает?
Датасет: 5–7 разных задач классификации и регрессии.
21. Влияние размера обучающей выборки на качество
Постройте learning curves для 5+ алгоритмов: как меняется качество при увеличении train set от 100 до 100 000 объектов. Определите, когда «больше данных» перестаёт помогать для каждого метода.
Датасет: MNIST, Fashion-MNIST, California Housing, Adult Census.
22. Feature Selection: фильтры vs обёртки vs embedded
Сравните методы отбора признаков: mutual information, chi-squared (filter), RFE (wrapper), L1-регуляризация, tree importance (embedded). Постройте графики «число признаков vs качество» для каждого метода.
Датасет: Madelon (UCI), датасеты с >50 признаками (Kaggle).
23. Ансамбли с нуля: реализация и анализ
Реализуйте с нуля Bagging, Random Subspace, AdaBoost (без sklеarn). Сравните вашу реализацию с библиотечной. Визуализируйте, как решающие границы меняются при добавлении новых базовых моделей.
Датасет: синтетические 2D данные (make_moons, make_circles) + 1–2 реальных.

Е. Нейронные сети (MLP)

24. Архитектура имеет значение: глубина vs ширина
Исследуйте, как число слоёв и нейронов влияет на аппроксимацию. Сравните shallow vs deep сети при одинаковом числе параметров. Постройте heatmap «ширина × глубина → качество».
Датасет: MNIST, Fashion-MNIST, синтетические функции.
25. Регуляризация MLP: Dropout vs Weight Decay vs BatchNorm
Сравните методы регуляризации: по отдельности и в комбинациях. Исследуйте overfit gap (train acc – test acc) для каждого метода. Найдите оптимальные гиперпараметры.
Датасет: CIFAR-10 (flatten), MNIST, табличные данные.
26. Оптимизаторы: SGD vs Adam vs RMSprop
Детальное сравнение: сходимость, чувствительность к learning rate, поведение на разных ландшафтах loss. Визуализируйте траектории на 2D функциях (Rosenbrock, Rastrigin). Сравните с learning rate scheduling.
Датасет: синтетические 2D функции + MNIST/Fashion-MNIST.
27. Инициализация весов: от нулей до Kaiming
Исследуйте влияние инициализации (нули, случайная, Xavier, He/Kaiming) на сходимость и финальное качество. Постройте графики распределения активаций по слоям для каждой инициализации. Сравните shallow и deep сети.
Датасет: MNIST, Fashion-MNIST, CIFAR-10 (flatten).

28. Аппроксимация сложных функций с помощью MLP

Обучите MLP аппроксимировать математические функции разной сложности: $\sin(x)$, $x \cdot \sin(1/x)$, фракталы, хаотические отображения. Исследуйте, как архитектура и активация влияют на качество аппроксимации. Визуализируйте «провалы» обучения.

Датасет: синтетические 1D/2D функции (генерация самостоятельно).

29. Transfer Learning для табличных данных

Обучите MLP на большом табличном датасете, заморозьте первые слои и дообучите на маленьком. Работает ли transfer learning для таблиц? Сравните с обучением с нуля и с классическими алгоритмами.

Датасет: Adult Census $\rightarrow$ Bank Marketing, большой Kaggle $\rightarrow$ маленький UCI.

F. Прикладные проекты

30. Прогнозирование цен на авиабилеты

Предскажите стоимость перелёта по маршруту, дате, авиакомпании, классу. Feature engineering из дат (день недели, праздники, сезон). Сравните линейные модели, бустинг и MLP.

Датасет: Flight Price Prediction (Kaggle).

31. Диагностика заболеваний по медицинским показателям

Классификация наличия заболевания по анализам крови, давлению, возрасту и т.д. Особое внимание: интерпретируемость (SHAP, feature importance), метрики для медицины (sensitivity, specificity).

Датасет: Heart Disease (UCI), Diabetes (Kaggle), Breast Cancer Wisconsin.

32. Предсказание победителя киберспортивного матча

Feature engineering из игровой статистики (KDA, gold, objectives). Сравните классификацию и MLP. Исследуйте, какие признаки наиболее предсказательны на разных стадиях матча.

Датасет: Dota 2 Matches (Kaggle), League of Legends Ranked Games.

33. Рекомендательная система фильмов

Collaborative filtering (user-based, item-based) + content-based подход. Реализуйте матричную факторизацию и MLP-based рекомендации. Сравните метрики: RMSE, Precision@K, NDCG.

Датасет: MovieLens 100K/1M, Netflix Prize.

34. Предсказание оценки ресторана по отзывам и метаданным

Регрессия / классификация рейтинга. Комбинируйте текстовые признаки (TF-IDF отзывов) с табличными (локация, цена, кухня). Исследуйте, что важнее: текст или метаданные.

Датасет: Yelp Dataset, Zomato Restaurants (Kaggle).

35. Предсказание задержки авиарейса

Бинарная классификация: будет ли рейс задержан >15 мин. Feature engineering из расписания, погоды, аэропорта, дня недели. Оцените бизнес-стоимость ошибок (FP vs FN).

Датасет: US Flight Delay (Kaggle), Bureau of Transportation Statistics.

Требования к проекту

Обязательная часть

1. EDA и предобработка

- Описание датасета: размер, типы признаков, целевая переменная
- Визуализация распределений (гистограммы, box-plot, корреляционная матрица)
- Обработка пропусков, выбросов, категориальных признаков
- Feature engineering (минимум 2–3 новых признака с обоснованием)

2. Классические ML-модели

- Минимум 3 разных алгоритма (tree-based, linear, ensemble)
- Подбор гиперпараметров (GridSearch / RandomSearch / Optuna)
- Кросс-валидация (не менее 5 фолдов)

3. Нейронная сеть MLP

- Архитектура: обоснование числа слоёв, нейронов, активации
- Графики обучения: loss и метрика на train/val по эпохам
- Применение хотя бы одного метода регуляризации (Dropout / BN / WD)

4. Сравнение и выводы

- Таблица: все модели, метрики (accuracy / F1 / RMSE / ROC-AUC), время обучения
- Анализ: почему одна модель лучше другой, в чём причина
- Содержательные выводы (не «модель X лучше», а «почему»)

Бонусная часть (желательно)

- +5 — SHAP / feature importance визуализация и анализ
- +5 — Stacking / Blending нескольких моделей
- +5 — Публикация на GitHub с README и requirements.txt
- +5 — Дополнительное исследование (ablation study, error analysis, fairness)

Частые ошибки

- Нет кросс-валидации — оценка на одном train/test split ненадёжна
- Нет графиков обучения MLP — невозможно понять, переобучается ли сеть
- Выводы вида «Random Forest лучше» без объяснения причин
- Утечка данных (data leakage): fit на всём датасете, потом split
- Сравнение моделей на разных метриках

Полезные ресурсы

- Kaggle Datasets: <https://www.kaggle.com/datasets>
- UCI ML Repository: <https://archive.ics.uci.edu/>
- OpenML: <https://www.openml.org/>
- Scikit-learn docs: <https://scikit-learn.org/>
- PyTorch tutorials: <https://pytorch.org/tutorials/>
- SHAP: <https://shap.readthedocs.io/>

Q&A

По всем вопросам: тг чат ML старт или @artemovma